

# Tarea. Ajuste de Modelo ARIMA

André Marx Puente Arévalo

3/12/2020


Con los datos del INPC, estime varios modelos ARIMA y explique con cuál de ellos se queda y ¿por qué?

```
# Cargamos las librerías que vamos a usar
library(astsa)
library(forecast)
library(tseries)

# Cargamos la serie de datos a usar
serie<-read.csv("/Users/AndrePuente/Documents/Series de Tiempo/Excel/DatosTarea.csv")

# Para graficar nuestros datos, primero los transformamos en una serie de tiempo
INPC<-c(serie$INPC)
serie<-ts(INPC,frequency = 12,start = c(2005,1))
# Graficamos
plot(serie, main = "Serie Original")
```

**Serie Original**




Primero le disminuiré la varianza a la serie:

```
LNSerie <- log(serie)

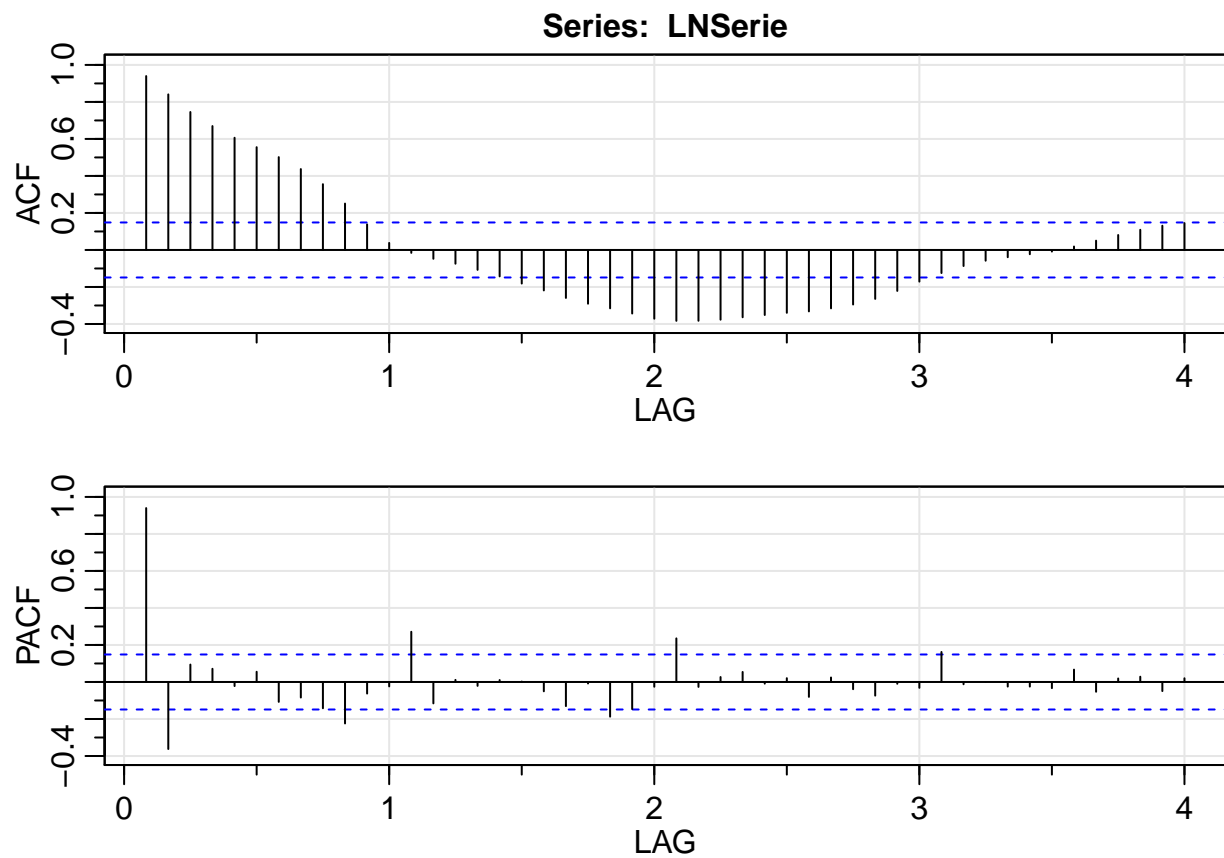
#Graficamos la nueva serie
plot(LNSerie, main = "Logaritmo Natural de la Serie")
```

## Logaritmo Natural de la Serie



Graficamos las autocorrelaciones:


```
acf2(LNSerie)
```



Observando las correlaciones anteriores nos damos cuenta que la serie presenta cierta estacionalidad, por lo que le aplicaremos diferencias.

```
dLNSerie <- diff(LNSerie)

# Graficamos las autocorrelaciones
acf2(dLNSerie)
```



Observando lo obtenido en las autocorrelaciones tras haber aplicado logaritmo y la diferencia, propondré mis modelos:

### Propuesta 1

```
# Ajustamos el primer modelo
modelo1 <- arima(dLNSerie, order = c(1,1,1))
summary(modelo1)

##
## Call:
## arima(x = dLNSerie, order = c(1, 1, 1))
##
## Coefficients:
##      ar1      ma1
##    0.3317 -1.0000
## s.e.  0.0715  0.0149
##
## sigma^2 estimated as 0.006126:  log likelihood = 199.77,  aic = -393.55
##
## Training set error measures:
##              ME      RMSE      MAE  MPE  MAPE      MASE      ACF1
## Training set 0.001842482 0.07805224 0.05679624 -Inf  Inf  0.8041979 0.04676816
```

### Propuesta 2

```
modelo2 <- arima(dLNSerie, order = c(2,1,1))
summary(modelo2)
```

```
##
## Call:
## arima(x = dLNSerie, order = c(2, 1, 1))
##
## Coefficients:
##          ar1          ar2          ma1
##      0.3798   -0.1471   -1.0000
## s.e.  0.0748    0.0747    0.0153
##
## sigma^2 estimated as 0.005986:  log likelihood = 201.69,  aic = -395.38
##
## Training set error measures:
##              ME          RMSE          MAE  MPE MAPE          MASE          ACF1
## Training set 0.001939549 0.07715275 0.05617757 -Inf  Inf  0.795438 -0.0193806
```

### Propuesta 3

```
modelo3 <- arima(dLNSerie, order = c(2,1,0))
summary(modelo3)
```

```
##
## Call:
## arima(x = dLNSerie, order = c(2, 1, 0))
##
## Coefficients:
##          ar1          ar2
##      -0.2860   -0.2221
## s.e.   0.0737    0.0734
##
## sigma^2 estimated as 0.008254:  log likelihood = 175.26,  aic = -344.53
##
## Training set error measures:
##              ME          RMSE          MAE  MPE MAPE          MASE          ACF1
## Training set 0.001110709 0.09060084 0.06614948 -Inf  Inf  0.9366337 -0.06108219
```

### Propuesta 4

```
modelo4 <- arima(dLNSerie, order = c(1,1,0))
summary(modelo4)
```

```
##
## Call:
## arima(x = dLNSerie, order = c(1, 1, 0))
##
## Coefficients:
##          ar1
##      -0.2340
## s.e.   0.0734
##
## sigma^2 estimated as 0.008681:  log likelihood = 170.8,  aic = -337.61
##
## Training set error measures:
##              ME          RMSE          MAE  MPE MAPE          MASE          ACF1
## Training set 0.00109514 0.09291269 0.06895433 -Inf  Inf  0.9763486 -0.05131984
```

### Propuesta 5

```
modelo5 <- arima(dLNSerie, order = c(0,1,1))
summary(modelo5)
```

```
##
## Call:
## arima(x = dLNSerie, order = c(0, 1, 1))
##
## Coefficients:
##          ma1
##        -1.0000
## s.e.    0.0166
##
## sigma^2 estimated as 0.00684:  log likelihood = 189.57,  aic = -375.15
##
## Training set error measures:
##              ME      RMSE      MAE  MPE MAPE      MASE      ACF1
## Training set 0.001648347 0.08247197 0.06200341 -Inf  Inf 0.8779281 0.3236714
```

## Propuesta 6

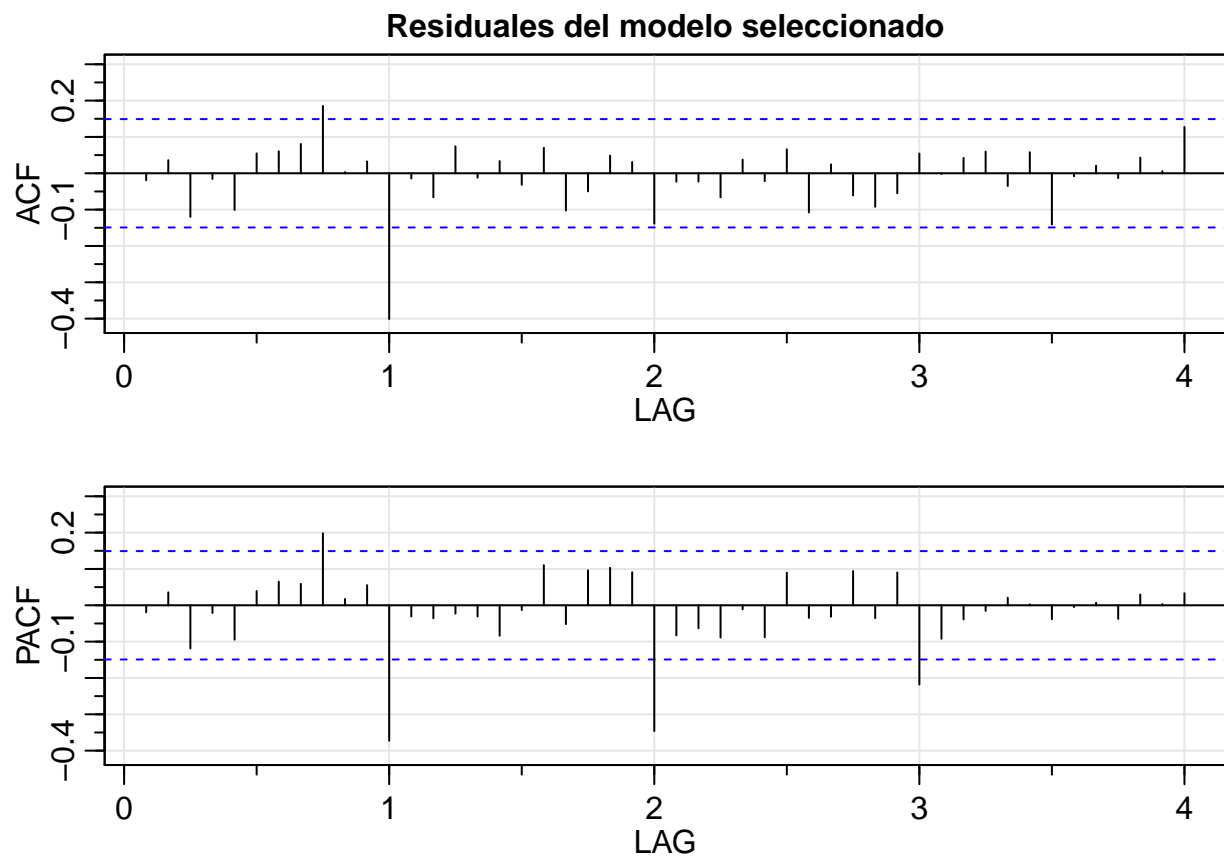
```
modelo6 <- arima(dLNSerie, order = c(2,1,3))
summary(modelo6)
```

```
##
## Call:
## arima(x = dLNSerie, order = c(2, 1, 3))
##
## Coefficients:
##          ar1      ar2      ma1      ma2      ma3
##        0.9000 -0.4545 -1.5499 0.7131 -0.1632
## s.e. 0.2547 0.1907 0.2878 0.4316 0.1875
##
## sigma^2 estimated as 0.005877:  log likelihood = 203.15,  aic = -394.31
##
## Training set error measures:
##              ME      RMSE      MAE  MPE MAPE      MASE      ACF1
## Training set 0.00219979 0.07644559 0.05629264 -Inf  Inf 0.7970672 0.002743297
```

En **conclusión**, entre todos los modelos que propusimos, el que disminuyó más el AIC y la  $R^2$  fue el modelo2, por lo que elegiré ese modelo.

Graficamos las autocorrelaciones de los residuales del modelo2:


```
acf2(modelo2$residuals, main = "Residuales del modelo seleccionado")
```



Ajustamos el modelo a nuestros datos y lo graficamos:

```
Ajuste <- fitted.values(modelo2)
EAjustado <- exp(Ajuste)
plot(EAjustado, main = "Modelo Ajustado")
```


## Modelo Ajustado



Ahora graficamos a los residuales:

```
residuales <- residuals(modelo2)  
plot(residuales, main = "Residuales")
```

## Residuales



Ahora, realizamos el pronóstico para febrero y marzo del 2020:



```
pronostico <- predict(modelo2, n.ahead = 2)
pronostico
```

```
## $pred
##           Feb           Mar
## 2020 0.057168237 0.000480374
##
## $se
##           Feb           Mar
## 2020 0.07758228 0.08314158
```

```
# Graficamos los pronosticos
plot(forecast(modelo2,h=2),type="l",main="Pronóstico", xlim = c(2015, 2020.5))
```

